

Estudo sobre Sum-Product Networks e Aprendizagem Profunda

Renato Lui Geh

Instituto de Matemática e Estatística
Universidade de São Paulo

29 de junho de 2016



INSTITUTO DE MATEMÁTICA E ESTATÍSTICA
UNIVERSIDADE DE SÃO PAULO

Índice

- 1 Motivação
- 2 Sum-Product Networks
- 3 Aprendizado
- 4 Código
- 5 Referências e Bibliografia

Outros modelos

- Redes Bayesianas
- Redes de Markov
- Máquinas restritas de Boltzmann


Representam uma distribuição de probabilidade de forma compacta.
Mas...

Inferência intratável ou aproximada!

Aprendizado difícil!

Largura de árvore

Largura de árvore grande \Rightarrow inferência intratável.



SPNs computam inferência exata e tratável mesmo quando a largura de árvore é grande.

Arquiteturas profundas

DBNs: Deep Belief Networks [HS06]

CDBNs: Convolutional Deep Belief Networks [Lee+09]

DBMs: Deep Boltzmann Machines [SH10]

Arquiteturas profundas são mais interessantes [Ben09]. Mas...

Inferência mais difícil ainda!

Aprendizado mais difícil também!

Representatividade

1. Modelos tratáveis existentes

vs

2. Modelos baseados em grafos clássicos

vs

3. Redes Soma-Produto (Sum-Product Networks)

1 e 3 ambos tem inferência e aprendizado tratáveis.

$$3 >_g 1$$

Definição


Definição

Uma SPN tem uma definição recursiva. Definimos que uma SPN S_i pode ser apenas:

- (i) Uma distribuição monovariável $p(\mathbf{X})$ ou;
- (ii) Um nó soma tal que $S_i = \sum_{j \in Ch(i)} w_{ij} v_j$ onde para cada filho $j, k \in Ch(i)$, $Sc(S_j) = Sc(S_k)$ ou;
- (iii) Um nó produto tal que $S_i = \prod_{j \in Ch(i)} v_j$ onde para cada filho $j, k \in Ch(i)$, $Sc(S_j) \cap Sc(S_k) = \emptyset$.

[GD13]

Definição



Uma visão mais intuitiva

Nós internos: variáveis latentes – camadas ocultas:

⊕: mistura de distribuições – “semelhança entre instâncias”;

⊗: independência entre variáveis.

Nós folhas: Valoração/instanciação das variáveis.

Uma visão mais intuitiva

Nós internos: variáveis latentes – camadas ocultas:

\oplus : mistura de distribuições – “semelhança entre instâncias”;

\otimes : independência entre variáveis.

Nós folhas: Valoração/instanciação das variáveis.





Figura: *Learning the Structure of Sum-Product Networks Using Clustering on Variables*, Dennis e Ventura [DV12]

Inferência



$$\lambda_{X_1} = 1, \lambda_{\bar{X}_1} = 0, \lambda_{X_2} = 1, \lambda_{\bar{X}_2} = 1$$

$$S = \Pr(X_1 = \text{true}) = f(x_1) = 0.69$$

Aprendizado


Queremos aprender uma SPN profunda.

Lembrando...

- + semelhanças nos dados
- × independência entre variáveis

Nós somas

Queremos achar *clusters* de instâncias semelhantes: k-means clustering.



Cada cluster $i = 0..k - 1$ será um filho de um nó soma.

Note: todo filho tem mesmo escopo pois todo cluster tem mesmo escopo.

Nós produtos

Queremos achar conjuntos independentes de variáveis: grafo de independência.

Definição

Um grafo de independência é um grafo $G = (X, E)$ com variáveis X como vértices e arestas $E = \{e_{ij} : X_i - X_j \iff X \not\perp Y\}$.

Como testar independências par-a-par? Teste de independência por Chi-Quadrado ou por Entropia.

Nós produtos

Proposição

Seja um grafo de independência $G = (X, E)$, os k -subgrafos $H_0, \dots, H_k \subseteq G$ desconexos tem escopos independentes par-a-par.

Cada subgrafo H_i será um filho de um nó produto.

Note: todo filho tem escopo disjunto de outro filho pois todo filho é independente par-a-par de seus irmãos.

Nós folhas

Queremos uma distribuição monovariável: contagem de frequências quando $|X| = 1$.

Considere um vetor p onde cada índice $i = 0, \dots, n$ é uma possível valoração distinta e única de uma variável X e que X pode tomar até n valorações diferentes. Dizemos que p é então uma distribuição sobre X . Se p obedece os axiomas da Teoria de Probabilidade, então p é uma distribuição de probabilidade monovariável com domínio discreto.

Seja um vetor v de tamanho k onde cada v_i é uma valoração de X . Então v é um vetor de frequência de X .

Então p será:

$$p_i = \sum_{v_j=i} \frac{1}{k} = \Pr(X = i)$$

Aprendizado estrutural de SPNs

Algoritmo 1 LearnSPN [GD13]

Input Conjunto \mathbf{X} de variáveis, conjunto \mathbf{I} de instâncias

Output Uma SPN resultante do aprendizado estrutural

- 1: **if** $|\mathbf{X}| = 1$ **then**
 - 2: Retorna uma distribuição monovariável de \mathbf{X}
 - 3: **end if**
 - 4: Tente dividir as variáveis \mathbf{X} em q partições $\mathbf{X}_1, \dots, \mathbf{X}_q$ onde \mathbf{X}_i é (aproximadamente) independente de todo \mathbf{X}_j para $i \neq j$.
 - 5: **if** dá para dividir **then**
 - 6: **return** $\prod_{i=1}^q \text{LearnSPN}(\mathbf{X}_i, \mathbf{I})$
 - 7: **else**
 - 8: Divida as instâncias \mathbf{I} em partições $\mathbf{I}_1, \dots, \mathbf{I}_k$ tal que \mathbf{I}_i seja uma coleção de instâncias mais similares possíveis entre si.
 - 9: **return** $\sum_{i=1}^k \frac{|\mathbf{I}_i|}{|\mathbf{I}|} \text{LearnSPN}(\mathbf{X}, \mathbf{I}_i)$
 - 10: **end if**
-

Código

Se der tempo, agora vou mostrar o código. 😊

Referências e Bibliografia I



Yoshua Bengio. “Learning Deep Architectures for AI”. Em: *Foundations and Trends in Machine Learning* (2009).



Aaron Dennis e Dan Ventura. “Learning the Architecture of Sum-Product Networks Using Clustering on Variables”. Em: *Advances in Neural Information Processing Systems* 25 (2012).



Robert Gens e Pedro Domingos. “Learning the Structure of Sum-Product Networks”. Em: *International Conference on Machine Learning* 30 (2013).



Geoffrey E. Hinton e Ruslan R. Salakhutdinov. “Reducing the Dimensionality of Data with Neural Networks”. Em: *Science Magazine* (2006).

Referências e Bibliografia II



Honglak Lee et al. “Convolutional Deep Belief Networks for Scalable Unsupervised Learning of Hierarchical Representarions”. Em: *International Conference on Machine Learning (ICML 2009)* (2009).



Ruslan R. Salakhutdinov e Geoffrey E. Hinton. “Deep Boltzmann Machines”. Em: *International Conference on Artificial Intelligence and Statistics (AISTATS)* (2010).